

**Universidade Estadual Paulista “Júlio de Mesquita Filho”  
FCT — Faculdade de Ciências e Tecnologia  
DMC — Departamento de Matemática e Computação  
Bacharelado em Ciência da Computação**

**Trabalho de Conclusão de Curso  
Revisão bibliográfica**

**Aplicação de métodos de Inpainting em imagens digitais**

**Gustavo Becelli do Nascimento**

**Orientador:** Prof. Dr. Almir Olivette Artero

**Presidente Prudente  
2023**

## SUMÁRIO

<b>1</b>	<b>Introdução</b>	<b>2</b>
<b>2</b>	<b>Fundamentação teórica</b>	<b>3</b>
2.1	Conceito . . . . .	3
2.1.1	Métodos baseados em patches . . . . .	4
2.1.2	Métodos baseados em aprendizado . . . . .	4
2.2	Aplicações . . . . .	5
2.3	Trabalhos relacionados . . . . .	5
<b>3</b>	<b>Conclusão</b>	<b>5</b>
<b>4</b>	<b>Referências bibliográficas</b>	<b>5</b>

# 1 Introdução

O Inpainting de Imagens é o processo de preencher regiões faltantes ou danificadas de uma imagem com o intuito de restaurá-la ou melhorar sua aparência. Este é um problema amplamente estudado em visão computacional e possui uma vasta oportunidades de aplicações, incluindo o restauro de obras artísticas e fotografias danificadas, a remoção de objetos de imagens e síntese de texturas (CRIMINISI; PÉREZ; TOYAMA, 2004).

Esta área de pesquisa tem sido estudada há várias décadas. Os primeiros trabalhos sobre o tema surgiram na década de 1950, mas foi somente a partir dos anos 1990 que o inpainting começou a ser utilizado de maneira mais ampla.

(ELHARROUSS et al., 2019) apresenta uma revisão sobre o inpainting de imagens, descrevendo os principais métodos e aplicações. Neste campo, existem várias técnicas para o inpainting de imagens, cada tal com suas próprias vantagens e desvantagens. Uma abordagem popular é apresentada em (BERTALMIO et al., 2000), a qual introduz uma técnica de inpainting baseada no conceito de complementar uma região de uma imagem existente. Neste trabalho é utilizado equações parciais diferenciais para propagar informações das bordas da região danificada para o centro da região, permitindo que o algoritmo estime como os pixels devem ser restaurados.

Uma das contribuições mais significativas para o campo de inpainting de imagem é o desenvolvimento do "Método de Marcha Rápida" (TELEA, 2004), um algoritmo eficiente que usa equações diferenciais parciais para propagar informações de pixels conhecidos para os pixels desconhecidos na região de inpainting. Este algoritmo tem sido amplamente utilizado em várias aplicações e foi implementado em muitas bibliotecas de software, incluindo a biblioteca de código aberto de visão computacional OpenCV (OPENCV, 2000). Este método tem demonstrado produzir resultados de alta qualidade para uma ampla variedade de tipos de imagem e cenários, e se tornou uma das referências para avaliar o desempenho de outros algoritmos de inpainting.

Nos últimos anos, houve um aumento de interesse em utilizar métodos baseadas em aprendizado de máquina, como redes adversárias gerativas (GANs) e redes neurais convolucionais (CNNs) (PATHAK et al., 2016), para resolver o problema de inpainting. Esses métodos têm o potencial de aprender padrões e estruturas complexas a partir de grandes conjuntos de dados, o que pode ser usado para gerar resultados de inpainting de alta qualidade. No entanto, esses métodos podem ser computacionalmente caros e podem exigir grandes quantidades de dados de treinamento para obter bons resultados.

Hoje, o inpainting é utilizado em uma variedade de aplicações. Dentre elas, está incluída o restauro de obras de arte danificadas, a remoção de objetos de imagens (como nuvens em imagens de sensoriamento remoto) e até mesmo a remoção de imperfeições de fotografias. Além disso, pode-se utilizar os mesmos conceitos de restauração para modificar as perspectivas de imagens, como é apresentado em (HUANG et al., 2014).

O principal problema encontrado neste campo de pesquisa são a escolha do método de inpainting mais adequado para cada tipo de imagem e cenário. Este fator se deve às desvantagens que os métodos existentes proporcionam (SALEM, 2021). Em geral, os maiores desafios são:

- **Preservação da consistência e estrutura da imagem de entrada:** muitos modelos geradores podem gerar imagens visualmente agradáveis, mas que não correspondem perfeitamente com a vizinhança ou à textura da imagem original.
- **Preservação de pequenos detalhes:** este problema é particularmente desafiador para imagens com texturas complexas, como imagens de paisagens naturais, ou a área que

está sendo restaurada é muito grande.

- **Reconstruir objetos sobrepostos:** quando um objeto é parcial ou completamente sobreposto, como um objeto que está coberto por uma nuvem, o modelo gerador pode não ser capaz de reconstruir o objeto original.
- **Preenchimento de grandes regiões:** a geração de imagens de alta qualidade quando há uma grande região a ser reconstruída ainda é um problema desafiador.
- **Desempenho computacional:** a maioria dos métodos de inpainting de imagens que geram imagens de alta qualidade são computacionalmente caros, o que torna difícil sua aplicação em tempo real.

A etapa posterior a este trabalho, iniciada com as disciplinas de Trabalho de Conclusão de Curso I e II, será a implementação de diferentes técnicas de preenchimento de imagens (inpainting) e sua aplicação em exemplos reais. O objetivo será comparar os resultados obtidos e avaliar a eficiência computacional e os resultados de cada um deles. É esperado que, com a aplicação desta sequência de trabalhos, sejam obtidos resultados de alta qualidade, com um tempo de processamento aceitável. Além disso, caso oportuno, serão realizadas otimizações no código fonte, para aumentar a qualidade dos resultados ou diminuir o tempo de processamento, a fim de tornar os métodos mais adequados para aplicações em tempo real.

## 2 Fundamentação teórica

A gama de aplicações processo de inpainting em imagens digitais é ampla, uma vez que não se limita a um único domínio. A técnica pode ser aplicada em diversas áreas, tais como a medicina, engenharia, arquitetura, entre outras, as quais serão mais exploradas mais a fundo no tópico 2.2. Além disso, o conceito de inpainting, inicialmente apresentado em 1, não agrega apenas as ideias de restauração de imagens ou remoção de objetos, mas também a construção e reconstrução de imagens (YOU; YOU; PAN, 2019), a preservação da privacidade (por exemplo, borramento de rostos e placas de veículos automotivos) em imagens públicas (GOOGLE, 2022), ao preenchimento de lacunas em imagens de satélites (MAALOUF et al., 2009), entre outros possíveis usos, aos quais alguns serão mais explorados no prosseguir desta revisão. Por fim, o tópico 2.3 apresenta os trabalhos relacionados ao tema.

### 2.1 Conceito

Neste trabalho, o escopo de inpainting de imagens pode ser compreendido como uma técnica utilizada para preencher regiões vacantes ou danificadas em uma imagem digital. O objetivo do inpainting é reconstruir as regiões afetadas de forma que o resultado final seja o mais visualmente plausível possível, ou seja, que a imagem resultante seja natural à ótica humana e não apresente artefatos visuais, enquanto preserva a coerência e consistência da imagem original. Há diversas formas de se implementar o processo de inpainting, sendo que a escolha do método a ser utilizado depende do domínio de aplicação, das características da imagem, do tipo de máscara, entre outros fatores. Contudo, é comum distinguir duas variedades de métodos que são amplamente utilizados: os métodos baseados em *patches*, os quais utilizam informações da estrutura da imagem para preencher lacunas, e os métodos baseados em aprendizado, os quais comumente utilizam grandes quantidades de dados para serem treinados, sendo que os métodos baseados em aprendizado são os mais recentes e geralmente apresentam resultados mais satisfatórios.

### 2.1.1 Métodos baseados em patches

Os métodos baseados em patches utilizam informações dos pixels e da região vizinha das regiões que estão vacantes ou danificadas para preencher as lacunas. Estes métodos são baseados no princípio de que a patches próximos e similares ao alvo são os mais adequados para preencher a região. É possível ainda, dentro desta estratégia, distinguir dois tipos de métodos: os métodos baseados em amostras, tais que utilizam amostras próximas da região-alvo para preencher a lacuna, e os métodos baseados em síntese de textura que utilizam a textura das regiões conhecidas para preencher a lacuna.

**Métodos baseados em amostras:** estes métodos utilizam amostras das regiões conhecidas para reconstruir a região danificada. Assume-se que a região corrompida possui pixels semelhantes a dos seus vizinhos. Essa estratégia é simples e eficiente computacionalmente, em especial para imagens com texturas e estruturas mais simples. Contudo, não é produz resultados satisfatórios para lidar com imagens mais compostas, como imagens com texturas complexas, imagens com bordas irregulares, imagens com objetos com texturas semelhantes, etc.

**Métodos baseados em síntese de textura:** estes métodos, por sua vez, métodos baseados em texturas utilizam as informações das texturas das regiões conhecidas para sintetizar novos pixels para a região vacante. Esta estratégia assume que a área vizinha ao alvo possui texturas semelhantes, o que viabiliza propagar as bordas e frequências para preenchimento. Estes métodos podem produzir resultados satisfatórios para imagens com texturas complexas, embora encontrem dificuldades para lidar com imagens com bordas ou padrões irregulares, imagens com objetos com texturas semelhantes, entre outras.

Estas técnicas também são conhecidas como "clássicas", pois elas foram as primeiras a serem desenvolvidas. Elas produzem resultados satisfatórios para imagens com texturas e estruturas simples, mas não são eficazes para imagens mais complexas.

### 2.1.2 Métodos baseados em aprendizado

Os métodos baseados em aprendizado, por sua vez, utilizam técnicas de aprendizado de máquina, como redes neurais convolucionais (CNNs) e redes generativas adversárias (GANs) para preencher a região danificada. Estas técnicas "aprendem" a reconstruir a região danificada a partir de um conjunto de dados de imagens com e sem máscara. Estes métodos são mais recentes e apresentam resultados mais satisfatórios, em especial para imagens com texturas complexas, imagens com bordas irregulares, imagens com objetos com texturas semelhantes, etc. Contudo, estes métodos são mais complexos e computacionalmente mais custosos.

**Redes neurais convolucionais:** utilizam uma CNN para reconstruir as regiões faltantes. Estes métodos se beneficiam da habilidade das CNNs de aprender as características de uma imagem e conseguem produzir bons resultados para imagens com texturas e estrutura complexas. A rede é treinada em um vasto conjunto de dados de imagens e aprende a reconhecer padrões e as características das imagens. Após o treinamento, a rede utiliza o conhecimento adquirido para gerar novos pixels para a região danificada, ainda preservando a região que a cerca.

**Redes generativas adversárias:**

Os métodos baseados em aprendizado de máquina costumam lidar consistentemente com imagens contendo texturas e estruturas complexas, e apresentam resultados mais coerentes e realistas, embora estes métodos serem mais complexos e computacionalmente mais custosos.

\* Otimizações

\*\*\* Qualidade

- Estrutura da imagem (textura, bordas, etc) - Patch-based inpainting (usar patches de imagens sem máscara para preencher a máscara) - Edge-preserving inpainting (preservar bordas)

- Priorizar o inpainting de regiões de maior importância, normalmente localizadas em áreas de alta frequência - Usar redes neurais pode ser uma alternativa para otimizar o processo de inpainting - Inpainting guiado (o usuário insere a máscara) - Context-aware inpainting (usar informações de contexto para melhorar a qualidade do resultado) - Representação esparsa (pesquisar) - GANs - CNNs - Deep learning - Total Variation (vi no Fountoura) - non local (vi duas vezes)

\*\*\*Computacional - Profiling (análise de desempenho) - FPGAs - Crop - Paralelismo - Estruturas de dados - Otimização de acesso a memória

- Aceleração de hardware (GPU) - Instruções de vetorização (SIMD) - Vectorizing loops - Aproximações de funções - Cálculo incremental - Linguagens compiladas

## 2.2 Aplicações

## 2.3 Trabalhos relacionados

# 3 Conclusão

# 4 Referências bibliográficas

BERTALMIO, M.; SAPIRO, G.; CASELLES, V.; BALLESTER, C. Image inpainting. In: **Proceedings of the 27th Annual Conference on Computer Graphics and Interactive Techniques (SIGGRAPH 2000)**. [S.l.: s.n.], 2000.

CRIMINISI, A.; PÉREZ, P.; TOYAMA, K. Region filling and object removal by exemplar-based image inpainting. **IEEE Transactions on image processing**, IEEE, v. 13, n. 9, p. 1200–1212, 2004.

ELHARROUSS, O.; ALMAADEED, N.; AL-MAADEED, S.; AKBARI, Y. Image inpainting: A review. **Neural Processing Letters**, Springer Science and Business Media LLC, v. 51, n. 2, p. 2007–2028, dec 2019. ISSN 1573-773X.

GOOGLE. **Mediapipe-based library to redact faces from videos and images**. 2022. Disponível em: <<https://google.github.io/magritte/>>.

HUANG, J.; KANG, S.; AHUJA, N.; KOPF, J. Image completion using planar structure guidance. **ACM Transactions on Computer Systems**, Association for Computing Machinery (ACM), v. 33, n. 4, 2014. ISSN 0730-0301.

MAALOUF, A.; CARRE, P.; AUGEREAU, B.; FERNANDEZ-MALOIGNE, C. A bandelet-based inpainting technique for clouds removal from remotely sensed images. **IEEE Transactions on Geoscience and Remote Sensing**, v. 47, n. 7, p. 2363–2371, 2009.

OPENCV. **Open Source Computer Vision Library**. 2000. [⟨https://github.com/opencv/opencv⟩](https://github.com/opencv/opencv).

PATHAK, D.; KRÄHENBÜHL, P.; DONAHUE, J.; DARRELL, T.; EFROS, A. Context encoders: Feature learning by inpainting. In: **Computer Vision and Pattern Recognition (CVPR)**. [S.l.: s.n.], 2016.

SALEM, N. A survey on various image inpainting techniques. 09 2021.

TELEA, A. An image inpainting technique based on the fast marching method. **Journal of Graphics Tools**, v. 9, 01 2004.

YOU, S.; YOU, N.; PAN, M. Pi-rec: Progressive image reconstruction network with edge and color domain. **arXiv preprint arXiv:1903.10146**, 2019.